



Tecnológico de Monterrey

TC5035.10 Proyecto Integrador

Prof. Titular

Dra. Grettel Barceló Alonso

Prof. Asesor

Dr. Victor Munguia

Equipo 55

Integrantes

Edson Garduño Nolasco	A01795770
Ada Jimena Vargas Aguirre	A01701619
Irving Alan García Zapata	A01796793

Avance 0

Propuesta de proyecto y firma de convenios

27 de septiembre de 2026

Índice

Antecedentes.....	3
Entendimiento del negocio.....	4
Formulación del problema.....	4
Contexto.....	4
Objetivos.....	5
Preguntas clave.....	7
Involucrados.....	7
Entendimiento de los datos.....	8
Descripción de los datos.....	8
Técnica de ML.....	8
Arquitectura de IA generativa propuesta.....	9
Identificación de las variables.....	9
Bibliografía y referencias.....	10

Propuesta de proyecto y firma de convenios

Este documento presenta la propuesta inicial del proyecto ThreatLLM, cuyo objetivo es evaluar el uso de técnicas de Procesamiento de Lenguaje Natural y modelos de lenguaje para apoyar la clasificación automática de patrones de ataque descritos en reportes de inteligencia de amenazas. Además, se describe el contexto del problema, los datos disponibles y el enfoque metodológico que guiará el desarrollo del proyecto durante el semestre.

Antecedentes

El proyecto ThreatLLM surge de la necesidad de mejorar el análisis de información de inteligencia de amenazas en entornos de ciberseguridad. La organización beneficiaria es el Laboratorio de Ciberseguridad del Centro de Investigación en Computación (CISEG-CIC-IPN), el cual participa en actividades relacionadas con la investigación y análisis de amenazas informáticas.

La información de Cyber Threat Intelligence se ha convertido en un recurso esencial para identificar amenazas emergentes, compartir indicadores de compromiso y fortalecer las capacidades de defensa de las organizaciones [1]. Estos reportes suelen estar redactados en lenguaje natural y describen comportamientos, técnicas y procedimientos utilizados por actores maliciosos.

El análisis de esta información requiere que especialistas revisen manualmente los reportes para identificar patrones de ataque y clasificarlos de acuerdo con marcos de referencia como MITRE ATT&CK. Este proceso puede ser lento y consumir recursos especializados. La información de Cyber Threat Intelligence (CTI) se ha convertido en un componente esencial para identificar patrones de ataque y fortalecer las capacidades defensivas de las organizaciones [2].

Por esta razón, el proyecto propone aplicar técnicas de Procesamiento de Lenguaje Natural (NLP) y modelos de lenguaje para automatizar parte de este análisis y apoyar el proceso de clasificación de patrones de ataque.

Entendimiento del negocio

Formulación del problema

Los analistas deben identificar y clasificar comportamientos maliciosos utilizando marcos de referencia ampliamente aceptados como MITRE ATT&CK [3]. Este proceso requiere tiempo, experiencia y análisis manual, lo que puede retrasar la respuesta ante incidentes y dificultar el procesamiento oportuno de la información disponible.

El reto consiste en determinar si es posible utilizar modelos de Procesamiento de Lenguaje Natural y modelos de lenguaje para clasificar automáticamente descripciones de comportamientos maliciosos, asociarlas con técnicas de ataque específicas, y apoyar al momento de priorizar una amenaza con base en su severidad. La Fig. 1 muestra el flujo manual que actualmente siguen los analistas para interpretar reportes CTI.



Fig. 1 Flujo actual de análisis manual de amenazas.

Contexto

Según [4], se estima que el costo promedio global de una brecha de datos es de 4.99 millones de dólares. Asimismo, la creciente cantidad de reportes CTI trae consigo una variedad de retos: en primera instancia, la priorización. Sin una métrica cuantitativa de severidad, cada alerta debe ser manualmente evaluada, lo que a su vez genera:

- Fatiga de alertas

El 76% de analistas de seguridad reportan *burnout* a pesar del aumento de uso de IA y automatización de tareas, debido principalmente a cargas laborales pesadas[5].

- Aumento en el tiempo medio de detección y contención

El tiempo promedio para identificar y contener una brecha aumentó a 247 días respecto a años anteriores; asimismo, se encontró que las organizaciones que presentaron brechas con ciclos de vida superiores a 200 días, se enfrentaron a un incremento de 12% en promedio sobre sus costos [4].

- Priorización incorrecta

Ataques de alto impacto pasan desapercibidos mientras que se investigan alertas menores. Aunado a esto, en promedio se reciben 4,330 alertas diarias y solo el 37% se investigan [6].

La cantidad de información relacionada con amenazas cibernéticas continúa creciendo constantemente, entre ellos la cantidad de reportes CTI ha generado la necesidad de desarrollar mecanismos automatizados que permitan procesar y analizar grandes volúmenes de información de manera eficiente [1]. Los reportes de inteligencia de amenazas contienen información valiosa para los analistas de seguridad, pero gran parte de estos datos se encuentran en formato no estructurado

La automatización de tareas de clasificación mediante técnicas de inteligencia artificial puede reducir significativamente el esfuerzo requerido para analizar esta información y permitir que los especialistas concentren su atención en actividades de mayor valor estratégico.

Además, los avances recientes en modelos de lenguaje y representaciones semánticas han demostrado resultados prometedores para tareas de clasificación y comprensión de texto, lo que convierte a este proyecto en una oportunidad relevante para evaluar dichas tecnologías dentro del ámbito de la ciberseguridad. Los modelos basados en Transformers han demostrado resultados sobresalientes en tareas de comprensión y clasificación de texto [7].

Objetivos

Objetivo general

Desarrollar y evaluar una solución basada en Procesamiento de Lenguaje Natural y modelos de lenguaje capaz de clasificar automáticamente descripciones de comportamientos maliciosos en técnicas de ataque definidas dentro del marco MITRE ATT&CK [3].

Objetivos específicos

- Analizar y comprender la estructura de los datos proporcionados por el framework LADDER.
- Preparar y transformar los datos para su utilización en modelos de aprendizaje automático.
- Implementar modelos de referencia para la clasificación de patrones de ataque.
- Evaluar representaciones semánticas basadas en embeddings [8] para mejorar el desempeño de clasificación.
- Comparar distintas alternativas de modelado y seleccionar la de mejor rendimiento.
- Explorar el uso de modelos de lenguaje para apoyar el proceso de triage y análisis de amenazas.

La Fig. 2 presenta el flujo propuesto incorporando ThreatLLM (que engloba los pasos 2,3 y 4) como apoyo al proceso de clasificación y priorización.



Fig. 2 Flujo propuesto utilizando ThreatLLM.

Preguntas clave

- ¿Es posible clasificar automáticamente técnicas de ataque a partir de descripciones textuales?
- ¿Qué nivel de desempeño puede alcanzarse utilizando modelos de NLP y aprendizaje supervisado?
- ¿Los embeddings semánticos ofrecen mejores resultados que enfoques tradicionales como TF-IDF?
- ¿Qué modelo presenta el mejor equilibrio entre precisión, complejidad y costo computacional?
- ¿Puede un modelo de lenguaje servir como apoyo para el proceso de triage realizado por los analistas de un SOC?
- ¿Qué tan bien clasifica un modelo de decisión sin entrenamiento (JEV) comparado con nuestro pipeline supervisado ya entrenado?

Involucrados

TABLA I
Participantes del proyecto

Participante	Rol	Etapa(s) del proyecto	Nivel/tipo de participación	Participación
Dr. Juan Arturo Nolasco Flores	Sponsor del proyecto	Todas	Revisión periódica	Facilita recursos, seguimiento y validación del proyecto
Dr. Victor Munguia	Asesor académico	Todas	Orientación metodológica y técnica en cada sesión de asesoría	Supervisión metodológica y técnica
Ada Jimena Vargas Aguirre	Integrante del equipo	Todas	Ejecutor	Desarrollo técnico, implementación y evaluación de modelos
Edson Garduño Nolasco	Integrante del equipo	Todas	Ejecutor	Análisis de datos y evaluación experimental
Irving Alan García Zapata	Integrante del equipo	Todas	Ejecutor	Investigación, documentación y elaboración de entregables
CISEG-CIC-IPN	Organización beneficiaria	Antecedentes, validación del alcance	Provee contexto del caso de uso	Contexto de aplicación y validación del caso de uso

Entendimiento de los datos

Descripción de los datos

Los datos empleados provienen del framework LADDER (Looking Beyond IoCs: Automatically Extracting Attack Patterns from External CTI) presentado en [9]. Estos se encuentran en 3 datasets complementarios, correspondientes a las etapas del pipeline TTPClassifier descrito en la Sección 4.3 en [9]. En la Tabla 2 se incluyen el propósito y formato según el dataset.

TABLA 2

Estructura y propósito de los datasets LADDER

Dataset	Propósito	Formato
sentence_classification	Clasificación binaria (ataque o no)	CSV, separador TAB (text,label)
entity_extraction	Extracción del span exacto de la acción maliciosa	IOB/IOB2, un token por línea
attack-pattern-matching-gt	Mapeo a técnicas MITRE ATT&CK	CSV (text, malware, label)

Estos datos son de acceso público y no cuentan con restricciones de uso para fines de investigación académica. Los datasets utilizados se encuentran disponibles en el repositorio oficial del framework LADDER [10].

Técnica de ML

La técnica principal utilizada será aprendizaje supervisado para clasificación de texto. Se dispone de ejemplos etiquetados donde una descripción textual de un comportamiento malicioso se encuentra asociada a una técnica específica del marco MITRE ATT&CK.

Como parte del proyecto se evaluarán distintas aproximaciones, incluyendo técnicas tradicionales de NLP, representaciones semánticas mediante embeddings y modelos basados en arquitecturas Transformer. Dentro de las alternativas a evaluar se encuentran arquitecturas modernas basadas en Transformers, como BERT y sus variantes [7].

Arquitectura de IA generativa propuesta

Se explorará y evaluará el uso de modelos de lenguaje (LLMs) como apoyo al proceso de clasificación y triage de amenazas. Estos modelos podrán utilizarse para interpretar

descripciones de eventos de seguridad, generar explicaciones complementarias y asistir a los analistas durante el proceso de revisión [7][8].

Como comparación adicional a los modelos supervisados, se explorará el uso de JEV de TypeSafe AI [11], un modelo de decisión estructurada de reciente lanzamiento, para evaluar su desempeño en la tarea de clasificación sin entrenamiento previo sobre el dataset del proyecto.

Identificación de las variables

El sistema procesa un reporte de CTI en distintas etapas, cada una con su propio esquema de entrada y salida (véase Tabla 3). En la etapa final de mapeo a técnicas MITRE ATT&CK, el sistema recibirá como entrada una descripción textual de un comportamiento malicioso identificado dentro del reporte, pudiendo utilizar la familia de malware asociada como información adicional para mejorar el desempeño de clasificación.

A partir de dicha información, el modelo deberá identificar la técnica de ataque más probable dentro del marco MITRE ATT&CK. De manera complementaria, se explorará el uso de modelos de lenguaje para generar explicaciones que ayuden a los analistas de ciberseguridad a comprender la clasificación realizada y faciliten el proceso de triage y análisis de amenazas.

TABLA 3

Entradas y salidas

Dataset	Entrada(s)	Salida	Ejemplo
sentence_classification	text (oración en lenguaje natural)	label (1/0, ataque o no)	“steal SMS messages” → 1
entity_extraction	token (palabra individual dentro de una oración)	label (ATK/O, parte del span de ataque o no)	“steal” → ATK, “the” → O
attack-pattern-matching-gt	text (descripción del comportamiento) malware (familia asociada)	label (ID de técnica de MITRE ATT&CK)	text = “Capture screenshot”, malware = “SpyDealer” → T1513

Bibliografía y referencias

- [1] N. Rastogi, M. T. Alam, Y. Park and M. Shaon, "A Comparative Study of Cyber Threat Intelligence Sharing Platforms," in Proceedings of the ACM Workshop on Information Sharing and Collaborative Security, Austin, TX, USA, 2020.
- [2] S. Barnum, "Standardizing Cyber Threat Intelligence Information with the Structured Threat Information eXpression (STIX)", MITRE Corporation, Bedford, MA, USA, 2012.
- [3] MITRE ATT&CK Framework. MITRE Corporation. [Online]. Available: <https://attack.mitre.org>. [Accessed: 27-Sep-2026].
- [4] IBM and Ponemon Institute, "Cost of a Data Breach Report 2026", 2026. [Online]. Available: <https://www.ibm.com/reports/data-breach>. [Accessed: 27-Sep-2026].
- [5] Tines, "Voice of Security | 2026 Report ", 2026. [Online]. Available: <https://www.tines.com/access/whitepaper/voice-of-security-2026/>. [Accessed: 27-Sep-2026].
- [6] Crogl and Ponemon Institute, "2026 State of SecOps Report", 2026. [Online]. Available: <https://www.crogl.com/resources/research/state-of-secops-ai> . [Accessed: 27-Sep-2026].
- [7] J. Devlin, M. W. Chang, K. Lee and K. Toutanova, "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding," in Proceedings of NAACL-HLT 2019, Minneapolis, MN, USA, 2019, pp. 4171-4186.
- [8] N. Reimers and I. Gurevych, "Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks," in Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing (EMNLP-IJCNLP), Hong Kong, China, 2019, pp. 3982-3992.
- [9] M. T. Alam, D. Bhusal, Y. Park and N. Rastogi, "Looking Beyond IoCs: Automatically Extracting Attack Patterns from External CTI," in Proceedings of the 26th International Symposium on Research in Attacks, Intrusions and Defenses (RAID '23), Hong Kong, China, 2023, pp. 92-108, doi: 10.1145/3607199.3607208.
- [10] AI for Security Research Group, "LADDER Framework Repository," GitHub. [Online]. Available: <https://github.com/aiforsec/LADDER>. [Accessed: 27-Sep-2026].
- [11] D. Almeida, "Introducing System One Models & Jev", TypeSafe AI. [Online]. Available: <https://typesafe.ai/blog/introducing-system-one-models-and-jev>. [Accessed: 27-Sep-2026].